


Statistiek

author : ian.claesen@gmail.com

2 juni 2026



Inhoudsopgave

1	Statistiek	3
1.1	Begrippen	3
2	toevalsveranderlijken	5
2.1	Inleiding voorbeeld	5
3	Rekenregels voor toevalsveranderlijken	6
4	De $\sqrt{n}$-wet	8
4.1	Voorbeeld	8
4.1.1	De verdeling van de dozen	8
4.1.2	Steekproef	8
4.1.3	Grafieken	9
4.1.4	Python voorbeeld	10
5	Continue verdeling	11
6	0–1 populatie of Bernoulli populatie	12
6.1	Inleiding	12
6.2	Definitie	12
6.2.1	Kansfunctie	12
6.2.2	Notatie	12
6.3	Eigenschappen	12
6.3.1	Verwachting (gemiddelde)	12
6.3.2	Variantie	12
6.3.3	Standaardafwijking	12
6.4	Voorbeelden	13
6.5	Visualisatie	13
6.6	Python voorbeeld	13
6.7	Toepassingen	13

7	De binomiale verdeling	14
7.1	Inleiding	14
7.1.1	Uitwerking van $(a + b)^n$ voor $n = 3$	14
7.1.2	Binomiale driehoek (binomium van Newton)	15
7.1.3	Algemeen voor $(a + b)^n$	15
7.2	Verwachting en variantie van de binomiale verdeling	16
7.3	De <code>scipy.stats.binom.cdf</code> -functie in Python	17
7.4	Benadering van de binomiale verdeling door de normale verdeling	18
7.4.1	Voorbeeld	19
8	De Centrale Limietstelling (CLT)	21
8.1	Inleiding	21
8.1.1	Formalisering	21
8.2	Intuïtie achter de CLT	21
8.2.1	Voorbeeld: Dobbelsteenworpen	21
8.3	Toepassingen van de CLT	22
8.4	Wanneer is de CLT van toepassing?	22
8.4.1	Praktische regel	22
8.5	Vergelijking met de $\sqrt{n}$ -wet	22
8.6	Python-simulatie: CLT in actie	22
9	Schatters	23
9.1	Notatieafpraak	23
9.2	Eigenschappen van een goede schatter	23
10	Voorbeelden van puntschattingen	25
10.1	Puntschatting van het populatiegemiddelde	25
10.2	Puntschatting van een proportie	25
10.3	Intervalschatting (vb. van een proportie)	26
10.4	B.I. voor een proportie p met $a\%$ -betrouwbaarheidsinterval	28
10.5	B.I. voor een normaal gemiddelde μ met $a\%$ -betrouwbaarheidsinterval	28
11	Toetsen van hypothesen	29
11.1	Inleiding	29
11.2	Tweezijdige test	30
11.3	Linkseenzijdige test	30
11.4	Rechtseenzijdige test	31
11.5	Samenvattende tabel	31

1 Statistiek

1.1 Begrippen

Getallen die zo'n beetje het "midden" aangeven van een reeks waarnemingen heten centrummaten [1, 2, 3]. Er zijn drie centrummaten:

- De **modus** is de waarneming die het meeste voorkomt, die met de hoogste frequentie [3].
- De **mediaan** is het middelste waarnemingsgetal. Om de mediaan te bepalen zet je eerst de waarnemingsgetallen in volgorde van klein naar groot. Is het aantal waarnemingsgetallen oneven dan is er echt een middelste. Is het aantal even dan zijn er twee middelste waarnemingsgetallen. De mediaan is het gemiddelde van die middelste twee [2].
- Het **gemiddelde** bereken je door alle waarnemingsgetallen op te tellen en te delen door het totale aantal [1].

Als er sprake is van een frequentietabel moet je elk waarnemingsgetal eerst met de frequentie vermenigvuldigen.

Noem je de waarnemingsgetallen $x_1, x_2, x_3, \dots$ dan is het gemiddelde $\bar{x}$.

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}$$

Er zijn drie spreidingsmaten:

- De **spreidingsbreedte** (ook wel variatiebreedte) is het verschil tussen hoogste en laagste waarnemingsgetal.
- De **kwartielfafstand** is het verschil tussen de mediaan van de grootste helft (het derde kwartiel) en de mediaan van de kleinste helft (eerste kwartiel) [6]. Om de kwartielen te bepalen zet je eerst de waarnemingsgetallen in volgorde van klein naar groot en verdeel je ze in twee helften. Vervolgens bepaal je van beide helften weer de mediaan.

voorbeeld oneven waarnemingen:

3	8	11	11	14	17	21	22	22	27	35
		Q_1			mediaan			Q_3		

spreidingsbreedte = $35 - 3 = 32$, kwartielfafstand = $Q_3 - Q_1 = 22 - 11 = 11$

voorbeeld even waarnemingen:

2	5	7	9	12	13	15	16	18	20	24	28
		Q_1			mediaan			Q_3			

Onderste helft: 2,5,7,9,12,13

Bovenste helft: 15,16,18,20,24,28

$$Q_1 = \frac{7+9}{2} = 8$$

$$Q_3 = \frac{18+20}{2} = 19$$

$$\text{mediaan} = \frac{13+15}{2} = 14$$

Q_1 en Q_3 worden berekend op dezelfde manier als de mediaan. Als de waarnemingsreeks uit een oneven aantal bestaat wordt de mediaan zelf niet meegerekend bij een helft. De 2 helften zijn daarom altijd even groot. Als een helft uit een even aantal bestaat is het kwartiel het gemiddelde van de middelste 2 getallen.

- De **standaardafwijking** (of standaarddeviatie) [4]:

$$\sigma_x = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2}$$

- De **variantie** [5]:

$$(\sigma_x)^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2 \quad (\sigma \text{ is de Griekse (kleine) letter sigma.})$$

- De **populatie, steekproef** [24]:
- De **enkelvoudige aselechte steekproef** [24]:

2 toevalsveranderlijken

2.1 Inleiding voorbeeld


Stel dat een vultoestel X zakjes nootjes vult. Op basis van een steekproef besluiten we dat:

- $P(X = 1) = 0.25$
- $P(X = 2) = 0.50$
- $P(X = 3) = 0.25$

Stel dat een tweede vultoestel B zakjes nootjes vult. Op basis van een steekproef besluiten we dat:

- $P(Y = 1) = 0.50$
- $P(Y = 2) = 0.25$
- $P(Y = 3) = 0.25$

We stoppen telkens 1 zakje van toestel X en 1 zakje van toestel Y in een doos Z .
Het aantal nootjes in de doos wordt dan :



Opmerking : een normaalverdeling kan je ook bekijken als een oneindig fijne discrete verdeling [9].

3 Rekenregels voor toevalsveranderlijken

Verwachting en Variantie van $Z = X + Y$

De verwachting en variantie van een som van twee onafhankelijke toevalsveranderlijken worden als volgt afgeleid [12, 5]:

$$\begin{aligned}\mu_Z &= \sum_{i=1}^n \left(\sum_{j=1}^m (P_i \cdot P_j \cdot (X_i + Y_j)) \right) \\&= \sum_{i=1}^n \left(P_i \cdot \sum_{j=1}^m ((X_i + Y_j) \cdot P_j) \right) \\&= \sum_{i=1}^n P_i \cdot \left(X_i + \sum_{j=1}^m P_j Y_j \right) \\&= \sum_{i=1}^n P_i \cdot (X_i + \mu_Y) \\&= \sum_{i=1}^n X_i P_i + \mu_Y \sum_{i=1}^n P_i \\&= \mu_X + \mu_Y \\&= \mu_Z\end{aligned}$$

$$\begin{aligned}\sigma_Z^2 &= \sum_{i=1}^n \left(\sum_{j=1}^m (P_i \cdot P_j \cdot ((X_i + Y_j) - \mu_Z)^2) \right) \\&= \sum_{i=1}^n \left(P_i \cdot \sum_{j=1}^m (P_j \cdot ((X_i + Y_j) - (\mu_X + \mu_Y))^2) \right) \\&= \sum_{i=1}^n \left(P_i \cdot \sum_{j=1}^m (P_j \cdot ((X_i - \mu_X) + (Y_j - \mu_Y))^2) \right) \\&= \sum_{i=1}^n \left(P_i \cdot \sum_{j=1}^m P_j \cdot ((X_i - \mu_X)^2 + 2(X_i - \mu_X)(Y_j - \mu_Y) + (Y_j - \mu_Y)^2) \right) \\&= \sum_{i=1}^n \left(P_i \cdot \left(\sum_{j=1}^m P_j \cdot (X_i - \mu_X)^2 + 2 \sum_{j=1}^m P_j (X_i - \mu_X)(Y_j - \mu_Y) + \sum_{j=1}^m P_j (Y_j - \mu_Y)^2 \right) \right) \\&= \sum_{i=1}^n (X_i - \mu_X)^2 P_i + 2 \sum_{i=1}^n \left((X_i - \mu_X) P_i \sum_{j=1}^m (Y_j - \mu_Y) P_j \right) + \sum_{j=1}^m (Y_j - \mu_Y)^2 P_j \\&= \sum_{i=1}^n (X_i - \mu_X)^2 P_i + 2 \cdot 0 + \sum_{j=1}^m (Y_j - \mu_Y)^2 P_j \\&= \sigma_X^2 + \sigma_Y^2\end{aligned}$$

Verwachting en Variantie van $Z = aX + bY$


$$\begin{aligned}
 \mu_Z &= \sum_{i=1}^n \left(\sum_{j=1}^m (P_i \cdot P_j \cdot (aX_i + bY_j)) \right) \\
 &= \sum_{i=1}^n \left(P_i \cdot \sum_{j=1}^m (P_j \cdot (aX_i + bY_j)) \right) \\
 &= \sum_{i=1}^n \left(P_i \cdot \left(aX_i \sum_{j=1}^m P_j + b \sum_{j=1}^m P_j Y_j \right) \right) \\
 &= \sum_{i=1}^n (aX_i + b\mu_Y) \cdot P_i \\
 &= a \sum_{i=1}^n X_i P_i + b\mu_Y \sum_{i=1}^n P_i \\
 &= a\mu_X + b\mu_Y
 \end{aligned}$$

$$\begin{aligned}
 \sigma_Z^2 &= \sum_{i=1}^n \left(\sum_{j=1}^m (P_i \cdot P_j \cdot ((aX_i + bY_j) - (a\mu_X + b\mu_Y))^2) \right) \\
 &= \sum_{i=1}^n \left(P_i \cdot \sum_{j=1}^m (P_j \cdot (a(X_i - \mu_X) + b(Y_j - \mu_Y))^2) \right) \\
 &= \sum_{i=1}^n \left(P_i \cdot \sum_{j=1}^m P_j \cdot (a^2(X_i - \mu_X)^2 + 2ab(X_i - \mu_X)(Y_j - \mu_Y) + b^2(Y_j - \mu_Y)^2) \right) \\
 &= \sum_{i=1}^n \left(P_i \cdot \left(a^2(X_i - \mu_X)^2 \sum_{j=1}^m P_j + 2ab(X_i - \mu_X) \sum_{j=1}^m P_j(Y_j - \mu_Y) + b^2 \sum_{j=1}^m P_j(Y_j - \mu_Y)^2 \right) \right) \\
 &= a^2 \sum_{i=1}^n (X_i - \mu_X)^2 P_i + 2ab \sum_{i=1}^n (X_i - \mu_X) P_i \sum_{j=1}^m (Y_j - \mu_Y) P_j + b^2 \sum_{j=1}^m (Y_j - \mu_Y)^2 P_j \\
 &= a^2 \sigma_X^2 + 0 + b^2 \sigma_Y^2 \\
 &= a^2 \sigma_X^2 + b^2 \sigma_Y^2
 \end{aligned}$$

4 De $\sqrt{n}$ -wet

4.1 Voorbeeld

We bekijken een vulmachine die bakjes vult. Het gewicht van de bakjes volgt een normaalverdeling [9]. De bakjes worden in een doos (in stippellijn) geplaatst.



4.1.1 De verdeling van de dozen

We hebben dozen met bakjes en nemen monsters [24, 16]:

$$B = \text{bakje}, D = \text{doos}, n = 3$$

$$D = n \cdot B$$

Hierbij geldt:

- Verwachtingswaarde van B : μ_B
- Verwachtingswaarde van D : $\mu_D = n \cdot \mu_B$
- Standaardafwijking van B : σ_B
- Standaardafwijking van D : $\sigma_D = \sqrt{n} \cdot \sigma_B$ (regel $\rightarrow \sigma_{2X}^2 = \sigma_X^2 + \sigma_X^2 = 2\sigma_X^2$)

4.1.2 Steekproef

We nemen één doos van de transportband (steekproef). Wat is het gemiddelde van de bakjes (B_1, B_2, B_3) in deze doos [22].

$$\bar{B} = \frac{B_1 + B_2 + B_3}{3}$$

Wat is de verwachtingswaarde van het gemiddelde van bakjes van de dozen.


$$\mu_{\bar{B}} = \mu_B$$

Wat is de verwachtingswaarde van de standaardafwijking van deze steekproef gemiddelden [23].
De standaardafwijking wordt kleiner volgens de wortel van n :


$$\sigma_{\bar{B}} = \frac{\sigma_B}{\sqrt{n}}$$

4.1.3 Grafieken

Hieronder zie je twee grafieken van een experiment met een doos van 3 bakjes en een doos van 10 bakjes. Je ziet dat de verdeling van steekproef gemiddelden van 10 bakjes korter bijeen liggen dan die bij 3 bakjes [16].



Figuur 1: Drie steekproeven van elk 3 punten (rood, blauw, groen) met gemiddelden (zie verticale lijnen).



Figuur 2: Drie steekproeven van elk 10 punten (rood, blauw, groen) met gemiddelden (zie verticale lijnen).

Opmerking : We zien dat bij een hoger aantal bakjes in een doos de spreiding van de steekproef gemiddelden kleiner is [17].

Figuur 3: Resultaat van de simulatie: verdeling van steekproefgemiddelden.

4.1.4 Python voorbeeld

Hier is de Python code voor het simuleren van een discrete verdeling om hetzelfde aan te tonen [39, 41].

```
import numpy as np
import pandas as pd
from itertools import product
import matplotlib.pyplot as plt

plt.style.use('ggplot')

# Gegeven waarden
Zpx = np.array([[0.25, 1], [0.45, 2], [0.3, 3]])
df_Zpx = pd.DataFrame(Zpx, columns=["kans", "waarde"])

repeats = [1, 2, 5, 10, 15]

plt.figure(figsize=(8, 5))

for repeat in repeats:
    combinaties = list(product(df_Zpx.itertuples(index=False), repeat=repeat))

    steekproefdata = []
    for combi in combinaties:
        kansen = [c.kans for c in combi]
        waarden = [c.waarde for c in combi]
        kans = np.prod(kansen)
        gemiddelde = np.mean(waarden)
        steekproefdata.append([kans, gemiddelde, waarden])

    df_steekproef = pd.DataFrame(steekproefdata, columns=["kans", "gemiddelde steekproef", "waarden"])

    df_gegroepeerd = df_steekproef.groupby('gemiddelde steekproef', as_index=False)['kans'].sum()
    df_gegroepeerd = df_gegroepeerd.sort_values('gemiddelde steekproef')

    mean = np.sum(df_gegroepeerd['gemiddelde steekproef'] * df_gegroepeerd['kans'])
    variance = np.sum((df_gegroepeerd['gemiddelde steekproef'] - mean) ** 2 * df_gegroepeerd['kans'])
    std_dev = np.sqrt(variance)

    plt.plot(df_gegroepeerd['gemiddelde steekproef'], df_gegroepeerd['kans'],
             marker='o', linewidth=1, label=f'repeat = {repeat}')

    plt.axvline(mean, linestyle='--', color='gray', alpha=0.7)
    plt.fill_betweenx([0, df_gegroepeerd['kans'].max()], mean - std_dev, mean + std_dev,
                     alpha=0.1, label=f'std dev (repeat {repeat})')

    print(f"Repeat = {repeat}: Mean = {mean:.3f}, Std Dev = {std_dev:.3f}")

plt.title('Verdeling van steekproefgemiddelden met standaardafwijking')
plt.xlabel('Steekproefgemiddelde (Xi)')
plt.ylabel('Totale kans (Pi)')
plt.legend(title='Repeat')
plt.grid(True)
plt.tight_layout()
plt.show()
```

5 Continue verdeling

6 0–1 populatie of Bernoulli populatie

6.1 Inleiding

Een **0–1 populatie** (of **Bernoulli populatie**) is een verzameling waar elke waarneming slechts twee mogelijke uitkomsten heeft [34]:

- **0** (mislukking, bv. “neen”, “defect”, “niet geslaagd”),
- **1** (succes, bv. “ja”, “goed”, “geslaagd”).

Dit type populatie wordt vaak gebruikt om situaties te modelleren waar een experiment of observatie slechts twee mogelijke resultaten heeft.

6.2 Definitie

Een toevalsveranderlijke X volgt een **Bernoulli-verdeling** als [34]:

$$P(X = 1) = p \quad \text{en} \quad P(X = 0) = 1 - p = q,$$

waar p de kans op succes is ($0 \leq p \leq 1$).

6.2.1 Kansfunctie

De kansfunctie van een Bernoulli-verdeelde toevalsveranderlijke X is:

$$P(X = x) = \begin{cases} p & \text{als } x = 1, \\ 1 - p & \text{als } x = 0. \end{cases}$$

6.2.2 Notatie

We noteren een Bernoulli-verdeelde toevalsveranderlijke als:

$$X \sim \text{Bernoulli}(p).$$

6.3 Eigenschappen

Voor een Bernoulli-verdeelde toevalsveranderlijke X gelden de volgende eigenschappen [34, 12]:

6.3.1 Verwachting (gemiddelde)

De verwachtingswaarde μ van X is:

$$\mu = E[X] = 1 \cdot P(X = 1) + 0 \cdot P(X = 0) = p.$$

6.3.2 Variantie

De variantie σ^2 van X is [5]:

$$\sigma^2 = \text{Var}(X) = p \cdot (1 - p)^2 + q \cdot (0 - p)^2 = p \cdot (1 - p)^2 + (1 - p) \cdot (0 - p)^2 = (1 - p) \cdot (p - p^2 + p^2) = pq$$

6.3.3 Standaardafwijking

De standaardafwijking σ is [4]:


$$\sigma = \sqrt{pq}.$$

6.4 Voorbeelden

- Een muntopgooi: $X = 1$ als het kop is ($p = 0.5$), $X = 0$ als het munt is.
- Kwaliteitscontrole: $X = 1$ als een product defect is ($p = 0.01$), $X = 0$ als het goed is.
- Medisch onderzoek: $X = 1$ als een patiënt een ziekte heeft ($p = 0.05$), $X = 0$ als de patiënt gezond is.

6.5 Visualisatie

Hieronder zie je de kansfunctie van een Bernoulli-verdeling met $p = 0.6$:



6.6 Python voorbeeld

Hier is een eenvoudig Python-voorbeeld om Bernoulli-experimenten te simuleren [39]:

```
import numpy as np

# Parameters
p = 0.6 # Kans op succes
n_experiments = 10 # Aantal experimenten

# Simuleer Bernoulli-experimenten
samples = np.random.binomial(1, p, n_experiments)

print("Resultaten van Bernoulli-experimenten:", samples)
```

6.7 Toepassingen

- **Statistische tests:** Bernoulli-verdelingen worden vaak gebruikt in hypothesetests, zoals de toets voor een enkele proportie [26].
- **Machine learning:** In logistische regressie wordt de Bernoulli-verdeling gebruikt om binaire uitkomsten te modelleren.
- **Kwaliteitscontrole:** Het testen of een product voldoet aan normen (goed/slecht).

7 De binomiale verdeling

7.1 Inleiding

7.1.1 Uitwerking van $(a + b)^n$ voor $n = 3$

De ontwikkeling van $(a + b)^n$ is gebaseerd op het binomium van Newton [14, 13]:


$$(a + b)^3 = C_0^3 \cdot a^0 b^3 + C_1^3 \cdot a^1 b^2 + C_2^3 \cdot a^2 b^1 + C_3^3 \cdot a^3 b^0$$

Met de coëfficiënten:

$$C_0^3 = 1, \quad C_1^3 = 3, \quad C_2^3 = 3, \quad C_3^3 = 1$$

Invullen:


$$(a + b)^3 = 1 \cdot b^3 + 3 \cdot ab^2 + 3 \cdot a^2 b + 1 \cdot a^3$$



Term	Keuzes (k_1, k_2, k_3)
$C_1^3 \cdot a \cdot b^2$	k_1, k_2, k_3 verdelen zonder volgorde over 1 positie (A)
$C_2^3 \cdot a^2 \cdot b$	k_1, k_2, k_3 verdelen zonder volgorde over 2 posities (A,A)

Zoals je ziet leveren bijvoorbeeld de keuzes k_1, k_2 en k_2, k_1 hetzelfde resultaat op: 2 successen. Daarom gebruiken we combinaties in de binomiale formule, en tellen we niet de volgorde, maar het aantal mogelijke sets van posities.

7.1.2 Binomiale driehoek (binomium van Newton)



7.1.3 Algemeen voor $(a + b)^n$

De formule van de binomiale verdeling is direct verbonden met het **binomium van Newton** [14], oftewel de ontwikkeling van $(a + b)^n$:

$$(a + b)^n = \sum_{i=0}^n C_i^n \cdot a^i \cdot b^{n-i}$$

Als we $a = p$ en $b = 1 - p$ invullen, dan krijgen we:

$$(p + (1 - p))^n = \sum_{i=0}^n C_i^n \cdot p^i \cdot (1 - p)^{n-i}$$

Omdat $p + (1 - p) = 1$, geldt:

$$1 = \sum_{i=0}^n P(X = i)$$

Dit toont aan dat de som van alle kansen gelijk is aan 1, zoals verwacht in een kansverdeling. De **structuur van de binomiale verdeling is dus dezelfde als die van het binomium van Newton**.

De **binomiale verdeling** beschrijft de kans op precies k successen bij n onafhankelijke pogingen, met kans p op succes per poging [10]. De formule luidt:

$$P(X = k) = \binom{n}{k} \cdot p^k \cdot (1 - p)^{n-k}$$

waarbij:

- $P(X = k)$: de kans op precies k successen,
- $\binom{n}{k}$: het aantal combinaties van n objecten op k posities (binomiale coëfficiënt) [13],
- p : kans op succes,
- $1 - p$: kans op mislukking.

De binomiale coëfficiënt wordt berekend met [13]:

$$\binom{n}{k} = \frac{n!}{(n - k)!k!}$$

7.2 Verwachting en variantie van de binomiale verdeling

De verwachting $\mu = E[X]$ van een binomiaal verdeelde stochastische variabele X is [10, 12]:

$$\begin{aligned}
 \mu = E[X] &= \sum_{k=0}^n k \cdot \binom{n}{k} p^k (1-p)^{n-k} \\
 &= \sum_{k=1}^n k \cdot \frac{n!}{(n-k)!k!} p^k (1-p)^{n-k} \quad (\text{term voor } k=0 \text{ is } 0) \\
 &= \sum_{k=1}^n \frac{n!}{(n-k)!(k-1)!} p^k (1-p)^{n-k} \\
 &= np \sum_{k=1}^n \frac{(n-1)!}{(n-k)!(k-1)!} p^{k-1} (1-p)^{(n-1)-(k-1)} \\
 &\quad \text{substitutie } m = n-1, j = k-1 \text{ en } n-k = m+1-(j+1) = m-j \\
 &= np \sum_{j=0}^m \frac{(m)!}{(m-j)!j!} p^j (1-p)^{m-j} \\
 &= np \sum_{j=0}^m \binom{m}{j} p^j q^{m-j} \\
 &= np(p+q)^m \quad \text{Zie theorie binomiale verdeling} \rightarrow (p+q)^m = \sum_{j=0}^m \binom{m}{j} p^j q^{m-j} \\
 &= np \cdot 1^m = np
 \end{aligned}$$

De variantie σ^2 is [10, 5]:

$$\begin{aligned}
 \sigma^2 &= E[X^2] - E[X]^2 \\
 &= \left(\sum_{k=0}^n k^2 \cdot \binom{n}{k} p^k q^{n-k} \right) - (np)^2 \quad (\text{Splits } k^2 = k(k-1) + k) \\
 &= \left(\sum_{k=0}^n k(k-1) \cdot \binom{n}{k} p^k q^{n-k} + \sum_{k=0}^n k \cdot \binom{n}{k} p^k q^{n-k} \right) - n^2 p^2 \\
 &= \left(\sum_{k=2}^n k(k-1) \cdot \frac{n!}{(n-k)!k!} p^k q^{n-k} + np \right) - n^2 p^2 \quad (\text{voor } k=0, 1 \text{ is de som } 0) \\
 &= \left(\sum_{k=2}^n \frac{n!}{(n-k)!(k-2)!} p^k q^{n-k} \right) + np - n^2 p^2 \quad (\text{Vereenvoudig de factorieel: } k! = k(k-1)(k-2)!) \\
 &= n(n-1)p^2 \sum_{k=2}^n \frac{(n-2)!}{(n-k)!(k-2)!} p^{k-2} q^{(n-2)-(k-2)} + np - n^2 p^2 \\
 &\quad (\text{Factor } n(n-1)p^2 \text{ uit en pas indices aan}) \\
 &\quad \text{substitutie } m = n-2, j = k-2 \text{ en } n-k = m-j \\
 &= n(n-1)p^2 \sum_{j=0}^m \frac{m!}{(m-j)!j!} p^j q^{m-j} + np - n^2 p^2 \\
 &= n(n-1)p^2 \sum_{j=0}^m \binom{m}{j} p^j q^{m-j} + np - n^2 p^2 \\
 &= n(n-1)p^2 (p+q)^m + np - n^2 p^2 \\
 &\quad (\text{Binomiale stelling: } (p+q)^m = 1 \text{ omdat } p+q=1) \\
 &= n(n-1)p^2 \cdot 1 + np - n^2 p^2 = n^2 p^2 - np^2 + np - n^2 p^2 \\
 &= np - np^2 = np(1-p) = npq
 \end{aligned}$$

7.3 De `scipy.stats.binom.cdf`-functie in Python

De `scipy.stats.binom.cdf`-functie maakt deel uit van de **SciPy**-bibliotheek [40], specifiek de module `scipy.stats`. Deze functie berekent de **cumulatieve verdelingsfunctie (CDF)** voor een **binomiale verdeling**.

Wiskundig:

$$\text{CDF}(k; n, p) = P(X \leq k) = \sum_{i=0}^k P(X = i)$$

waar X een binomiale stochastische variabele is.

Syntaxis van `stats.binom.cdf`

```
from scipy.stats import binom

binom.cdf(k, n, p, loc=0)
```

- **k**: Het aantal successen (inclusief) waarvoor je de cumulatieve kans wilt berekenen.
- **n**: Het aantal proeven.
- **p**: De kans op succes in één proef.
- **loc**: Optioneel. Verschuift de verdeling. Standaard is 0.

Voorbeeld

Stel, je gooit een eerlijke munt ($p = 0.5$) 10 keer ($n = 10$). Wat is de kans op **hooguit 5 keer kop**?

```
from scipy.stats import binom

n = 10 # Aantal proeven
p = 0.5 # Kans op succes (kop)
k = 5 # Aantal successen

kans = binom.cdf(k, n, p)
print(kans) # Uitvoer: ~0.6230
```

Dit betekent dat er een kans van **62,3%** is om 5 of minder keer kop te gooien in 10 worpen.

7.4 Benadering van de binomiale verdeling door de normale verdeling

Wanneer het aantal proeven n groot is ($n \geq 20$), kan de binomiale verdeling benaderd worden door een normale verdeling [10, 9].

Voorwaarden

De normale benadering is goed wanneer: $np \geq 5$ en $n(1-p) \geq 5$

Parameters

Voor een binomiale verdeling $X_b \sim \mathcal{B}(n, p)$ geldt:

$\mu = np$ en $\sigma = \sqrt{np(1-p)}$ De bijhorende normale benadering is:

$$X_n \approx \mathcal{N}(\mu, \sigma)$$


Continuïteitscorrectie

Omdat de binomiale verdeling discreet is en de normale verdeling continu, gebruiken we:

$$P(X_b = k) \approx P(k - 0.5 \leq X_n \leq k + 0.5)$$

Voorbeeld 1: symmetrisch geval ($p = 0.5$)


$$n = 20, p = 0.5, \mu = 10, \sigma \approx 2.236$$



De verdeling is symmetrisch en de normale benadering sluit zeer goed aan.

Voorbeeld 2: scheef geval ($p = 0.3$)

$$n = 20, p = 0.3, \mu = 6, \sigma \approx 2.049$$



De verdeling is scheef. De normale benadering is minder nauwkeurig, maar nog bruikbaar.

7.4.1 Voorbeeld

Een voetbalspeler heeft bij een trap naar het doel een trefkans van 60%. Hoeveel trappen moet hij minstens nemen om met een kans van 95% minstens 10 keer te scoren?

Oplossing:

Laat X het aantal geslaagde trappen zijn. Dan geldt:

$$X \sim \text{Bin}(n, 0,60)$$

We zoeken het kleinste n waarvoor:

$$P(X \geq 10) > 0,95 \quad \Leftrightarrow \quad P(X \leq 9) < 0,05$$

Exacte oplossing (Binomiale verdeling) [10]

We berekenen $P(X \leq 9)$ voor oplopende waarden van n totdat $P(X \leq 9) < 0.05$:

- Voor $n = 24$:

$$P(X \leq 9) \approx 0.946508 \quad (\text{Nog niet voldoende, want } 0.946508 > 0.05)$$

- Voor $n = 25$:

$$P(X \leq 9) \approx 0.034392 \quad (\text{Voldoet, want } 0.034392 < 0.05)$$

Dus is het kleinste n waarvoor $P(X \geq 10) > 0.95$:

$$\boxed{n = 25}$$

Benaderende oplossing (Normale verdeling) [9]

We benaderen $X \sim \text{Bin}(n, 0.60)$ door een normale verdeling:

$$X \approx \mathcal{N}(\mu, \sigma^2), \quad \text{met } \mu = np = 0.6n \text{ en } \sigma = \sqrt{np(1-p)} = \sqrt{0.24n}$$

We willen:

$$P(X \geq 10) > 0.95 \quad \Leftrightarrow \quad P(X \leq 9) < 0.05$$

Met continuïteitscorrectie:

$$P(X \leq 9.5) < 0.05$$

Standaardiseren:

$$\begin{aligned} P\left(Z \leq \frac{9.5 - \mu}{\sigma}\right) &< 0.05 \\ \frac{9.5 - 0.6n}{\sqrt{0.24n}} &\leq -1.645 \end{aligned}$$

Vermenigvuldigen met $\sqrt{0.24n}$ (let op: $\sqrt{0.24n} > 0$):

$$9.5 - 0.6n \leq -1.645\sqrt{0.24n}$$

Kwadraat nemen (beide kanten zijn negatief, dus de ongelijkheid keert om):

$$(9.5 - 0.6n)^2 \geq (1.645)^2 \cdot 0.24n$$

$$90.25 - 11.4n + 0.36n^2 \geq 0.6084n$$

$$0.36n^2 - 12.0084n + 90.25 \geq 0$$

Oplossen van de kwadratische vergelijking:

$$n = \frac{12.0084 \pm \sqrt{(12.0084)^2 - 4 \cdot 0.36 \cdot 90.25}}{2 \cdot 0.36}$$

$$n = \frac{12.0084 \pm \sqrt{144.2013 - 129.96}}{0.72}$$

$$n = \frac{12.0084 \pm \sqrt{14.2413}}{0.72}$$

$$n = \frac{12.0084 \pm 3.7738}{0.72}$$

Twee oplossingen:

$$n_1 = \frac{12.0084 - 3.7738}{0.72} \approx 11.43 \quad (\text{Niet relevant, want te klein})$$

$$n_2 = \frac{12.0084 + 3.7738}{0.72} \approx 21.92$$

Afgerond naar boven:

$$\boxed{n = 22}$$

Antwoord: Exact (binomiaal): $\boxed{n = 25}$. Benaderend (normaal): $\boxed{n = 22}$.

8 De Centrale Limietstelling (CLT)

8.1 Inleiding

De **Centrale Limietstelling (CLT)** is een fundamenteel resultaat in de statistiek [15]. Deze stelling zegt dat, **ongeacht de oorspronkelijke verdeling** van een populatie, de verdeling van het **steekproefgemiddelde** $\bar{X}$ van een voldoende grote steekproef ($n \geq 30$) **benaderd kan worden door een normale verdeling**, mits de steekproeven onafhankelijk en willekeurig getrokken zijn.

8.1.1 Formalisering

Stel dat $X_1, X_2, \dots, X_n$ onafhankelijke en identiek verdeelde toevalsveranderlijken zijn met:

- Verwachtingswaarde: $\mu = E[X_i]$
- Variantie: $\sigma^2 = Var(X_i) < \infty$

Dan geldt voor het steekproefgemiddelde $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ [22]:

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma}{\sqrt{n}}\right) \quad \text{voor grote } n$$

In woorden: de verdeling van $\bar{X}$ nadert een normale verdeling met:

- Gemiddelde: $\mu_{\bar{X}} = \mu$
- Standaardafwijking: $\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$


8.2 Intuïtie achter de CLT

De CLT verklaart waarom normale verdelingen zo vaak voorkomen in de natuur en in data [15]:

- Als je veel kleine, onafhankelijke effecten optelt (bijv. meetfouten, biologische variatie), dan wordt de totale verdeling normaal, zelfs als de individuele effecten niet normaal zijn.
- Voorbeeld: De hoogte van mensen in een populatie is het resultaat van veel genetische en omgevingsfactoren. De CLT verklaart waarom hoogtes normaal verdeeld zijn.

8.2.1 Voorbeeld: Dobbelsteenworpen

Stel dat je n keer met een eerlijke dobbelsteen gooit en het gemiddelde van de uitkomsten berekent. De verdeling van dit gemiddelde zal voor grote n normaal zijn, ook al is de verdeling van een enkele worp (uniform) niet normaal [15].



8.3 Toepassingen van de CLT

- **Steekproefverdelingen:** De CLT maakt het mogelijk om betrouwbaarheidsintervallen en hypothesetests uit te voeren, zelfs als de populatieverdeling onbekend is [21].
- **Kwaliteitscontrole:** In de industrie wordt de CLT gebruikt om de gemiddelde afmetingen van geproduceerde onderdelen te analyseren.
- **Polling:** Bij opiniepeilingen wordt de CLT gebruikt om de nauwkeurigheid van steekproefgemiddelden te schatten [22].

8.4 Wanneer is de CLT van toepassing?

De CLT werkt het best als [15]:

- De steekproefgrootte n groot genoeg is (meestal $n \geq 30$).
- De oorspronkelijke verdeling niet **extreem scheef** is (bijv. exponentiële verdelingen vereisen grotere n).
- De steekproeven **onafhankelijk** zijn.

8.4.1 Praktische regel

Voor de meeste toepassingen volstaat $n \geq 30$. Voor sterk scheve verdelingen (bijv. exponentieel) kan $n \geq 50$ nodig zijn [11].

8.5 Vergelijking met de $\sqrt{n}$ -wet

In de bestaande sectie over de $\sqrt{n}$ -wet laat je zien dat de standaardafwijking van het steekproefgemiddelde afneemt met $\frac{\sigma}{\sqrt{n}}$. Dit is **precies** wat de CLT voorspelt: de verdeling van $\bar{X}$ wordt niet alleen smaller, maar ook normaal [15, 23].

8.6 Python-simulatie: CLT in actie

Hieronder zie je een Python-simulatie die de CLT illustreert voor steekproeven uit een **exponentiële verdeling** (die sterk scheef is) [40, 41].

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import expon, norm

# Parameters
n_samples = [1, 5, 30, 100] # Steekproefgroottes
lambda_param = 1.0 # Parameter voor exponentiële verdeling
n_simulations = 10000 # Aantal simulaties

plt.figure(figsize=(12, 8))

for i, n in enumerate(n_samples, 1):
    sample_means = [np.mean(expon.rvs(scale=1/lambda_param, size=n)) for _ in range(n_simulations)]


    plt.subplot(2, 2, i)
    plt.hist(sample_means, bins=30, density=True, alpha=0.6, color='blue', label=f'n={n}')

    mu = 1 / lambda_param
    sigma = (1 / lambda_param) / np.sqrt(n)
    x = np.linspace(mu - 4*sigma, mu + 4*sigma, 100)
    plt.plot(x, norm.pdf(x, mu, sigma), 'r-', lw=2, label='Normale benadering')


    plt.title(f'Steekproefgrootte n={n}')
    plt.xlabel('Steekproefgemiddelde')
    plt.ylabel('Dichtheid')
    plt.legend()

plt.tight_layout()
plt.suptitle("Centrale Limietstelling: Exponentiële verdeling -> Normale verdeling", y=1.02)
plt.show()
```

Figuur 4: Simulatie van de CLT voor steekproeven uit een exponentiële verdeling. Naarmate n toeneemt, nadert de verdeling van $\bar{X}$ een normale verdeling.



Figuur 5: $n = 2$



Figuur 6: $n = 30$

Figuur 7: Simulatie van de Centrale Limietstelling voor steekproeven uit een exponentiële verdeling ($n = 2$ en $n = 30$). Naarmate n toeneemt, nadert de verdeling van $\bar{X}$ een normale verdeling.

9 Schatters

Statistisch onderzoek heeft vaak tot doel om via een steekproef informatie te verkrijgen over een onbekende waarde in de populatie — bijvoorbeeld het gemiddelde gewicht van een pakje koffie, of het aandeel defecte producten [19].

Omdat we meestal niet de volledige populatie kunnen onderzoeken, trekken we een steekproef [24]. Op basis van die steekproef berekenen we een waarde die een schatting is van de echte (onbekende) populatiewaarde. Zo’n berekende waarde noemen we een **schat**ter [19, 20].

9.1 Notatieafspraken

Een schatter duiden we meestal aan met een “hoedje” boven de letter:

Populatieparameter	Schat	ter uit de steekproef
p (proportie)	$\hat{p}$	
μ (gemiddelde)	$\bar{x}$ of $\hat{\mu}$	
σ (standaardafwijking)	s of $\hat{\sigma}$	

In het algemeen geldt: een onbekende parameter θ wordt geschat met een schatter $\hat{\theta}$ [19].

Wanneer gebruik je wat?

Proportie: Als je geïnteresseerd bent in het aandeel van een groep (bijv. “Hoeveel % van de klanten is tevreden?”) [25].

Gemiddelde: Als je de centrale tendens van een numerieke variabele wilt weten (bijv. “Wat is de gemiddelde leeftijd van de klanten?”) [1].

9.2 Eigenschappen van een goede schatter

- **Zuiverheid:** Een schatter is **zuiver** als de verwachtingswaarde van de schatter gelijk is aan de echte parameter [19]:

$$E(\hat{\theta}) = \theta$$

- **Efficiëntie:** Als er meerdere zuivere schatters bestaan, kiezen we de schatter met de kleinste spreiding (variantie). Zo'n schatter heet **efficiënt** [19].
- **Consistentie:** Een schatter is **consistent** als de standaardafwijking kleiner wordt naarmate de steekproefgrootte n toeneemt [19, 17]. Dat betekent dat de schatting dichter bij de werkelijke waarde komt naarmate n groter is.

10 Voorbeelden van puntschattingen

10.1 Puntschatting van het populatiegemiddelde

Een onderzoeker wil het gemiddelde gewicht van appels in een boomgaard schatten [20]. Hij neemt een steekproef van $n = 10$ appels. Hun gewichten (in gram) zijn:

145, 150, 148, 147, 149, 151, 146, 150, 148, 147

We berekenen het steekproefgemiddelde [22]:

$$\bar{x} = \frac{145 + 150 + 148 + 147 + 149 + 151 + 146 + 150 + 148 + 147}{10} = \frac{1481}{10} = 148,1$$

De puntschatting van het populatiegemiddelde μ is dus:

$$\hat{\mu} = \bar{x} = 148,1 \text{ gram}$$

Besluit: De onderzoeker schat het gemiddelde gewicht van een appel op 148,1 gram.

Uitleg: Je kent het echte gemiddelde gewicht van alle appels in de boomgaard niet.

Je schat dit met één enkele waarde: het gemiddelde van je steekproef.

Dit is een puntschatting van μ .

10.2 Puntschatting van een proportie

Een winkelier wil het percentage klanten schatten dat tevreden is over een nieuw kassasysteem [25, 20]. In een steekproef van $n = 50$ klanten antwoorden er $x = 38$ positief.

De steekproefproportie is:

$$\hat{p} = \frac{x}{n} = \frac{38}{50} = 0,76$$

De puntschatting van de populatieproportie p is dus:

$$\hat{p} = 0,76$$

Besluit: Op basis van de steekproef schat de winkelier dat 76% van zijn klanten tevreden is.

Uitleg: De populatieproportie p is onbekend.

Je gebruikt één enkele waarde uit de steekproef (namelijk $\hat{p} = 0,76$) om p te schatten.

Dit is dus een puntschatting van de echte proportie.

10.3 Intervalschatting (vb. van een proportie)

Situatie: Een leerkracht wil weten hoeveel procent van zijn leerlingen voldoende vertrouwen heeft in wiskunde. Hij ondervraagt een steekproef van $n = 100$ leerlingen, waarvan er $x = 62$ aangeven dat ze vertrouwen hebben.

Stap 1: Bereken de steekproefproportie : $\hat{p} = \frac{62}{100} = 0,62$

Stap 2: We construeren een 95%-betrouwbaarheidsinterval rond de steekproefproportie $\hat{p}$ om de werkelijke populatieproportie p te schatten [21]. Omdat de steekproef groot genoeg is, mogen we de normale benadering gebruiken.

Volgens de centrale limietstelling is de verdeling van de steekproefproportie $\hat{p}$ bij een voldoende grote steekproef ongeveer normaal verdeeld met [15]:

- een verwachtingswaarde $\mu_{\hat{p}} = p$ (de echte, onbekende proportie in de populatie),
- een standaardafwijking (ook wel de standaardfout genoemd) van [23]:

$$\sigma_{\hat{p}} = \frac{\sqrt{p(1-p)}}{\sqrt{n}}$$

Omdat we de werkelijke proportie p niet kennen, vervangen we die in de formule door de steekproefproportie $\hat{p}$. Zo krijgen we een benadering van de standaardfout (SE, standaard error):

$$SE = \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}}$$

Een betrouwbaarheidsinterval van 95% komt overeen met een symmetrisch gebied onder de standaard normale verdeling waarbinnen 95% van de waarden liggen [31]. Aan beide zijden blijft dus telkens 2,5% over, wat samen 5% buiten het interval is.


De bijbehorende kritieke waarde is [32]:

$$z = 1,96$$

Stap 3: Bereken het betrouwbaarheidsinterval (uitleg zie volgende pagina):

$$BI = \hat{p} \pm z \cdot SE = 0,62 \pm 1,96 \cdot \sqrt{\frac{0,62 \cdot (1 - 0,62)}{100}} = 0,62 \pm 1,96 \cdot \sqrt{\frac{0,2356}{100}}$$
$$\Rightarrow \text{Interval: } [0,5249; 0,7151]$$

Interpretatie: Met 95% betrouwbaarheid schatten we dat tussen 52,5% en 71,5% van alle leerlingen vertrouwen hebben in wiskunde.



Toelichting: De blauwe kromme stelt de normale verdeling voor van de steekproefproportie $\hat{p}$, met centrum op 0,62. Het gekleurde gebied tussen 0,5249 en 0,7151 bevat 95% van de kans — dit is het betrouwbaarheidsinterval [21].

Waar komen deze formules vandaan?

De formule voor het betrouwbaarheidsinterval is gebaseerd op de verdeling van de steekproefproportie [21, 15].

Wanneer we herhaald steekproeven trekken, zal de steekproefproportie $\hat{p}$ fluctueren rond de echte (onbekende) populatieproportie p . Voor voldoende grote steekproeven geldt volgens de centrale limietstelling:

$$\hat{p} \approx \mathcal{N}\left(p, \frac{p(1-p)}{n}\right)$$

Dit betekent dat:

- het gemiddelde van $\hat{p}$ gelijk is aan p ,
- de standaardafwijking gelijk is aan $\sqrt{\frac{p(1-p)}{n}}$ [23].

1. Standardiseren [32]

We brengen de verdeling terug naar de standaardnormale verdeling:

$$Z = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \Rightarrow Z \sim \mathcal{N}(0, 1)$$

2. 95% kansgebied

Voor de standaardnormale verdeling geldt [32, 31]:

$$P(-1,96 \leq Z \leq 1,96) = 0,95$$

Door Z in te vullen krijgen we:

$$P\left(-1,96 \leq \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \leq 1,96\right) = 0,95$$

3. Herschikken

Door alle termen te vermenigvuldigen met de standaardafwijking volgt:

$$P\left(\hat{p} - 1,96\sqrt{\frac{p(1-p)}{n}} \leq p \leq \hat{p} + 1,96\sqrt{\frac{p(1-p)}{n}}\right) = 0,95$$

Dit geeft de algemene vorm van een betrouwbaarheidsinterval [21]:

$$p \in \hat{p} \pm 1,96 \cdot \sqrt{\frac{p(1-p)}{n}}$$

4. Praktische benadering

Omdat p onbekend is, vervangen we deze door de steekproefproportie $\hat{p}$. Zo bekomen we de standaardfout [23]:

$$SE = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

5. Eindformule

Daaruit volgt het betrouwbaarheidsinterval:

$$BI = \hat{p} \pm z \cdot SE$$

waarbij voor 95% betrouwbaarheid geldt dat $z = 1,96$ [33].

10.4 B.I. voor een proportie p met $a\%$ -betrouwbaarheidsinterval

$$\left[\hat{p} - z_\alpha \cdot \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}, \quad \hat{p} + z_\alpha \cdot \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right]$$

Hierbij is z_α de kritieke waarde van de standaardnormale verdeling, horend bij het gekozen betrouwbaarheidsniveau [33, 31] (zie tabel hieronder):

Betrouwbaarheid a	80%	90%	95%	98%	99%
Kritieke waarde z_α	1,28	1,65	1,96	2,33	2,58

10.5 B.I. voor een normaal gemiddelde μ met $a\%$ -betrouwbaarheidsinterval

Wanneer de populatie normaal verdeeld is, of de steekproef voldoende groot is, dan is het steekproefgemiddelde $\bar{x}$ normaal verdeeld rond het populatiegemiddelde μ [9, 22], met een standaardfout van [23]:

$$SE = \frac{\sigma}{\sqrt{n}}$$

Daarmee kan het $a\%$ -betrouwbaarheidsinterval voor μ geschat worden met de formule [21]:

$$\left[\bar{x} - z_\alpha \cdot \frac{\sigma}{\sqrt{n}}, \quad \bar{x} + z_\alpha \cdot \frac{\sigma}{\sqrt{n}} \right]$$

Hierbij is z_α de kritieke waarde van de standaardnormale verdeling, horend bij het gekozen betrouwbaarheidsniveau [33] (zie tabel hieronder):

Betrouwbaarheid a	80%	90%	95%	98%	99%
Kritieke waarde z_α	1,28	1,65	1,96	2,33	2,58

11 Toetsen van hypothesen

11.1 Inleiding

In de statistiek willen we uitspraken doen over een populatie op basis van een steekproef. Een **statistische hypothese** is een veronderstelling over een onbekende populatieparameter (zoals het gemiddelde μ of een proportie p) [26, 35].

Via een **hypothesetoets** gaan we na of de steekproefdata voldoende bewijs leveren om een veronderstelling te verwerpen of te aanvaarden [26].

De twee hypothesen

Bij elke toets formuleren we steeds **twee tegengestelde hypothesen** [35]:

- De **nulhypothese** H_0 : de hypothese die we willen *toetsen*. Ze stelt dat er *geen* effect, verschil of afwijking is. We gaan er vanuit dat H_0 waar is, totdat het tegendeel bewezen wordt.
- De **alternatieve hypothese** H_1 : de hypothese die we willen *aantonen*. Ze stelt dat er *wel* een effect, verschil of afwijking bestaat.

Significantieniveau α

Het **significantieniveau** α is de maximale kans die we aanvaarden om H_0 ten onrechte te verwerpen (een zogenaamde **type I-fout**) [29, 28]. Typische waarden zijn $\alpha = 0,05$ (5%) of $\alpha = 0,01$ (1%).

Toetsingsgrootte en kritiek gebied

Om te beslissen of we H_0 al dan niet verwerpen, gaan we kijken waar de steekproef ligt volgens de veronderstelde steekproefverdeling (zie $\sqrt{n}$ in de formule). We berekenen de z -waarde van de steekproef in deze steekproefverdeling. [27]:

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$$

Deze z -waarde geeft aan hoeveel het steekproefgemiddelde verwijderd is van de veronderstelde populatiewaarde μ_0 onder H_0 .

Het **kritieke gebied** is het gebied van z -waarden waarvoor H_0 verworpen wordt [33]. De grenswaarden van dit gebied heten de **kritieke waarden** en worden bepaald door α .

Beslissingsregel

Situatie	Beslissing
z valt in het kritieke gebied	Verwerp H_0
z valt buiten het kritieke gebied	Geen reden om H_0 te verwerpen

Let op: “ H_0 niet verwerpen” betekent *niet* dat H_0 bewezen is — enkel dat de steekproef onvoldoende bewijs levert om ze te verwerpen [30].

Soorten toetsen

Afhankelijk van de alternatieve hypothese H_1 onderscheiden we drie types [26]:

Type	H_1	Kritiek gebied
Tweezijdig	$\mu \neq \mu_0$	Beide staarten
Links-eenzijdig	$\mu < \mu_0$	Linker staart
Rechts-eenzijdig	$\mu > \mu_0$	Rechter staart

De volgende voorbeelden werken elk type uit in detail.

11.2 Tweezijdige test

Context: Een fabrikant beweert dat de gemiddelde levensduur van zijn batterijen 100 uur is met een standaardafwijking van 10. Een consumentengroep wil nagaan of de werkelijke gemiddelde levensduur afwijkt van 100 uur.

Gegeven:

- $n = 40$, $\bar{x} = 96,2$, $\sigma = 10$, $\alpha = 0,05$

Hypothesen:


$$H_0 : \mu = 100 \quad \text{vs} \quad H_1 : \mu \neq 100$$

Toetsingsgrootheid [27]:

$$z = \frac{96,2 - 100}{10/\sqrt{40}} \approx -2,41$$

Kritieke waarden [33]: $z = \pm 1,96$

Besluit: $|-2,41| > 1,96 \Rightarrow$ verwerp H_0



11.3 Linkseenzijdige test

Context: Een school beweert dat haar leerlingen gemiddeld minstens 70% halen met een standaardafwijking van 6. Een inspecteur vermoedt dat ze lager scoren.

Gegeven:

- $n = 25$, $\bar{x} = 67$, $\sigma = 6$, $\alpha = 0,05$

Hypothesen:


$$H_0 : \mu \geq 70 \quad \text{vs} \quad H_1 : \mu < 70$$

Toetsingsgrootheid [27]:

$$z = \frac{67 - 70}{6/\sqrt{25}} = -2,5$$

Kritieke waarde [33]: $z = -1,645$

Besluit: $-2,5 < -1,645 \Rightarrow$ verwerp H_0



11.4 Rechtseenzijdige test

Context: Een producent van sportdrank beweert dat zijn product het uithoudingsvermogen van atleten verhoogt. Om dit te testen, voert een sportwetenschapper een experiment uit waarbij een groep proefpersonen de drank gebruikt en vervolgens een fietstest aflegt. De gemiddelde duur van eerdere testen zonder de drank bedraagt 35 minuten met een standaard afwijking van 4. De onderzoeker wil nagaan of de gemiddelde prestatieduur na gebruik van de drank significant hoger ligt.

Gegeven:

- $\bar{x} = 37,5$, $\mu_0 = 35$, $\sigma = 4$, $n = 36$, $\alpha = 0,01$

Hypothesen:


$$H_0 : \mu \leq 35 \quad \text{vs} \quad H_1 : \mu > 35$$

Toetsingsgrootheid [27]:

$$z = \frac{37,5 - 35}{4/\sqrt{36}} \approx 3,75$$

Kritieke waarde [33]: $z = 2,33$

Besluit: $3,75 > 2,33 \Rightarrow$ verwerp H_0



11.5 Samenvattende tabel

Testtype	Hypothesen	Doel
Tweezijdig	$H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$	Afwijking vaststellen
Links-eenzijdig	$H_0 : \mu \geq \mu_0$ vs $H_1 : \mu < \mu_0$	Lagere waarde aantonen
Rechts-eenzijdig	$H_0 : \mu \leq \mu_0$ vs $H_1 : \mu > \mu_0$	Hogere waarde aantonen

Referenties

- [1] “Gemiddelde,” *Wikipedia*, laatst gewijzigd op 15 mei 2026, <https://nl.wikipedia.org/wiki/Gemiddelde>.
- [2] “Mediaan,” *Wikipedia*, laatst gewijzigd op 12 mei 2026, <https://nl.wikipedia.org/wiki/Mediaan>.
- [3] “Modus (statistiek),” *Wikipedia*, laatst gewijzigd op 10 mei 2026, [https://nl.wikipedia.org/wiki/Modus_\(statistiek\)](https://nl.wikipedia.org/wiki/Modus_(statistiek)).
- [4] “Standaardafwijking,” *Wikipedia*, laatst gewijzigd op 18 mei 2026, <https://nl.wikipedia.org/wiki/Standaardafwijking>.
- [5] “Variantie (statistiek),” *Wikipedia*, laatst gewijzigd op 18 mei 2026, [https://nl.wikipedia.org/wiki/Variantie_\(statistiek\)](https://nl.wikipedia.org/wiki/Variantie_(statistiek)).
- [6] “Kwartiel,” *Wikipedia*, laatst gewijzigd op 8 mei 2026, <https://nl.wikipedia.org/wiki/Kwartiel>.
- [7] “Histogram,” *Wikipedia*, laatst gewijzigd op 5 mei 2026, <https://nl.wikipedia.org/wiki/Histogram>.
- [8] “Boxplot,” *Wikipedia*, laatst gewijzigd op 5 mei 2026, <https://nl.wikipedia.org/wiki/Boxplot>.
- [9] “Normale verdeling,” *Wikipedia*, laatst gewijzigd op 20 mei 2026, https://nl.wikipedia.org/wiki/Normale_verdeling.
- [10] “Binomiale verdeling,” *Wikipedia*, laatst gewijzigd op 14 mei 2026, https://nl.wikipedia.org/wiki/Binomiale_verdeling.
- [11] “Exponentiële verdeling,” *Wikipedia*, laatst gewijzigd op 7 mei 2026, https://nl.wikipedia.org/wiki/Exponenti%C3%ABle_verdeling.
- [12] “Verwachting (kansrekening),” *Wikipedia*, laatst gewijzigd op 14 mei 2026, [https://nl.wikipedia.org/wiki/Verwachting_\(kansrekening\)](https://nl.wikipedia.org/wiki/Verwachting_(kansrekening)).
- [13] “Binomiale coëfficiënt,” *Wikipedia*, laatst gewijzigd op 10 mei 2026, https://nl.wikipedia.org/wiki/Binomiale_co%C3%ABffici%C3%ABnt.
- [14] “Binomium van Newton,” *Wikipedia*, laatst gewijzigd op 10 mei 2026, https://nl.wikipedia.org/wiki/Binomium_van_Newton.
- [15] “Centrale limietstelling,” *Wikipedia*, laatst gewijzigd op 17 mei 2026, https://nl.wikipedia.org/wiki/Centrale_limietstelling.
- [16] “Steekproefverdeling,” *Wikipedia*, laatst gewijzigd op 12 mei 2026, <https://nl.wikipedia.org/wiki/Steekproefverdeling>.
- [17] “Wet van de grote getallen,” *Wikipedia*, laatst gewijzigd op 9 mei 2026, https://nl.wikipedia.org/wiki/Wet_van_de_grote_getallen.
- [18] “Momentgenererende functie,” *Wikipedia*, laatst gewijzigd op 5 mei 2026, https://nl.wikipedia.org/wiki/Momentgenererende_functie.
- [19] “Schatter (statistiek),” *Wikipedia*, laatst gewijzigd op 22 mei 2026, [https://nl.wikipedia.org/wiki/Schatter_\(statistiek\)](https://nl.wikipedia.org/wiki/Schatter_(statistiek)).
- [20] “Puntschatting,” *Wikipedia*, laatst gewijzigd op 22 mei 2026, <https://nl.wikipedia.org/wiki/Puntschatting>.
- [21] “Betrouwbaarheidsinterval,” *Wikipedia*, laatst gewijzigd op 22 mei 2026, <https://nl.wikipedia.org/wiki/Betrouwbaarheidsinterval>.

- [22] “Steekproefgemiddelde,” *Wikipedia*, laatst gewijzigd op 22 mei 2026, <https://nl.wikipedia.org/wiki/Steekproefgemiddelde>.
- [23] “Standaardfout,” *Wikipedia*, laatst gewijzigd op 22 mei 2026, <https://nl.wikipedia.org/wiki/Standaardfout>.
- [24] “Steekproef,” *Wikipedia*, laatst gewijzigd op 22 mei 2026, <https://nl.wikipedia.org/wiki/Steekproef>.
- [25] “Proportie (statistiek),” *Wikipedia*, laatst gewijzigd op 22 mei 2026, [https://nl.wikipedia.org/wiki/Proportie_\(statistiek\)](https://nl.wikipedia.org/wiki/Proportie_(statistiek)).
- [26] “Hypothesetoets,” *Wikipedia*, laatst gewijzigd op 20 mei 2026, <https://nl.wikipedia.org/wiki/Hypothesetoets>.
- [27] “Z-toets,” *Wikipedia*, laatst gewijzigd op 20 mei 2026, <https://nl.wikipedia.org/wiki/Z-toets>.
- [28] “Significantie (statistiek),” *Wikipedia*, laatst gewijzigd op 18 mei 2026, [https://nl.wikipedia.org/wiki/Significantie_\(statistiek\)](https://nl.wikipedia.org/wiki/Significantie_(statistiek)).
- [29] “Type I en type II fouten,” *Wikipedia*, laatst gewijzigd op 15 mei 2026, https://nl.wikipedia.org/wiki/Type_I_en_type_II_fouten.
- [30] “P-waarde,” *Wikipedia*, laatst gewijzigd op 16 mei 2026, <https://nl.wikipedia.org/wiki/P-waarde>.
- [31] “Betrouwbaarheidsniveau,” *Wikipedia*, laatst gewijzigd op 17 mei 2026, <https://nl.wikipedia.org/wiki/Betrouwbaarheidsniveau>.
- [32] “Z-verdeling,” *Wikipedia*, laatst gewijzigd op 22 mei 2026, <https://nl.wikipedia.org/wiki/Z-verdeling>.
- [33] “Kritieke waarden (statistiek),” *Wikipedia*, laatst gewijzigd op 19 mei 2026, https://nl.wikipedia.org/wiki/Kritieke_waarden.
- [34] “Bernoulli-verdeling,” *Wikipedia*, laatst gewijzigd op 22 mei 2026, <https://nl.wikipedia.org/wiki/Bernoulli-verdeling>.
- [35] “Nulhypothese,” *Wikipedia*, laatst gewijzigd op 20 mei 2026, <https://nl.wikipedia.org/wiki/Nulhypothese>.
- [36] “tikz.net,” *tikz.net*, <https://tikz.net/gaussians/>.
- [37] “PGFPlots Manual,” *SourceForge*, <http://pgfplots.sourceforge.net/pgfplots.pdf>.
- [38] “PGF/TikZ Manual,” *CTAN*, <https://tikz.dev/>.
- [39] “NumPy Documentation,” *NumPy*, <https://numpy.org/doc/stable/>.
- [40] “SciPy Documentation,” *SciPy*, <https://docs.scipy.org/doc/scipy/>.
- [41] “Matplotlib Documentation,” *Matplotlib*, <https://matplotlib.org/stable/contents.html>.